




Estado del Arte en Prompt Engineering

De escribir texto a diseñar interfaces cognitivas.




Síntesis de más de 1,500 papers y frameworks de producción (2024–2025)


La evolución hacia el diseño de sistemas cognitivos

- El debate terminó: el prompting puro no ha muerto, pero la frontera actual es el Agentic Systems y la optimización programática.
- Ya no interactuamos con un chatbot; orquestamos un pipeline.

2023: Prompting Lineal



2025: Arquitectura de Sistemas



El mapa taxonómico 2024-2025


Taxonomía basada en la revisión PRISMA de 1,565 papers (Schulhoff et al., 2024).

In-Context Learning (ICL)	Razonamiento	Agentic & Tools	Optimización Automática	Control de Salida
Zero-shot	Chain-of-Thought (CoT)	ReAct	APE	JSON-Mode
Few-shot	Tree-of-Thought (ToT)	Program-of-Thought (PoT)	DSPy	Multimodalidad
Many-shot	Graph-of-Thought (GoT)		Meta-prompting	Primado Psicológico

La base empírica del In-Context Learning


- Few-shot: Incrementa el performance entre +5-15% sobre Zero-shot. Funciona mejor con 3 a 8 ejemplos diversos.
- Many-shot (Gemini 1.5 Pro / Claude 3): El rendimiento experimenta retornos decrecientes después de ~100-200 ejemplos.

Key Insight: La diversidad de los ejemplos tiene mayor impacto que la cantidad bruta (Agarwal et al., 2024).



La evolución y los límites estructurales de Chain-of-Thought

- El Impacto: PaLM-540B saltó al 58% (+17.9%) en el benchmark GSM8K al forzar el razonamiento paso a paso (Wei et al., 2022).
- El Límite (NeurIPS 2024): CoT **colapsa** cuando el problema requiere generalización fuera de su distribución de entrenamiento (Stechly et al.).
- Regla de oro: Útil para matemáticas y lógica multi-step; contraproducente para tareas simples de un solo paso.




Razonamiento no lineal mediante árboles y grafos

Tree-of-Thought (ToT): Ideal para planeación. En el Game of 24, la eficacia salta del 4% (CoT) al 74% explorando múltiples caminos.

Graph-of-Thought (GoT): Permite que las rutas de razonamiento converjan. Mejora la calidad en tareas de interdependencia en un +62%.


Chain-of-Thought

Lineal




Tree-of-Thought

Ramificado




Graph-of-Thought

Interconectado




ReAct y la conexión con el mundo real

- **ReAct (Reason + Act):** Entrelaza el razonamiento interno con la ejecución de herramientas externas.
- **Eficacia:** Supera fuertemente a los baselines puros en ALFWorld (+34%).
- **El Riesgo en Producción:** Modelos débiles generan entre **40% y 90% de acciones inválidas**. El razonamiento de alta calidad es un prerequisite indispensable.



Delegación de cálculo computacional con Program-of-Thought


- **El Problema:** Los LLMs fallan en aritmética exacta.
- **La Solución (PoT):** Separar el razonamiento cognitivo del cómputo mecánico.
- **Impacto:** Supera a CoT consistentemente (+12% promedio) en datasets matemáticos al eliminar errores de cálculo (Chen et al., 2023).



```
def calculate_bond_price():  
    face_value = 1000  
    coupon_rate = 0.05  
    ytm = 0.04  
    years = 5  
    coupon = face_value * coupon_rate  
    price = sum([coupon / (1 + ytm)**t  
                for t in range(1, years+1)]) +  
            (face_value / (1 + ytm)**years)  
    return price
```


La automatización de la optimización programática

- El Fin del Prompt Manual: Tratar el prompt engineering como un problema de compilación declarativa.
- DSPy en la Práctica: Frameworks como DSPy auto-seleccionan los mejores few-shot examples y optimizan instrucciones.
- ROI: Logra en 10 minutos ($F1 \approx 0.6$) lo que a un humano le toma 20 horas de prueba y error, con ganancias de +10-20% en accuracy.




Control estricto de salida y contexto multimodal

- **JSON-Mode & Grammars:** El estándar de producción para integración de APIs. Garantiza el cumplimiento estructural.
- **Multimodal CoT:** El contexto visual es más potente que el textual. Los estímulos visuales mostraron una mejora del +15.96% frente al 12.82% verbal.

```
{  
  "entity": "Tesla",  
  "sentiment": "mixed",  
  "confidence": 0.82  
}
```



100% Compliance Validation



```
<image_description>                                     <ml>  
  Gráfico de barras mostrando crecimiento  
  exponencial en Q3, con una caída abrupta del  
  20% en Noviembre debido a interrupciones  
  logísticas.  
</image_description>
```


El impacto empírico del primado psicológico

- EmotionPrompt: Anexar estímulos emocionales o de presión psicológica mejora el output empíricamente.
- Resultados: +115% en el benchmark BIG-Bench y +10.9% en evaluaciones humanas (Li et al.).
- Precaución: Es altamente dependiente del modelo y la tarea. Puede agregar latencia y amplificar el sesgo.



Anti-patrones que destruyen el performance (Parte I)



Especificaciones vagas



Instrucciones 100% negativas



Lost in the middle (Instrucciones al final)



CoT para tareas simples



Single-example Few-shot



Definir audiencia, tono y constraints



Especificar la alternativa deseada



Colocar el query al final después de documentos



Direct prompting para cálculos de un paso



Usar 3 a 8 ejemplos diversos

Riesgos estructurales comunes en producción (Parte II)

❌ Instrucciones multi-parte sin estructura

✅ Separar en pasos etiquetados (evita caída del 30%)

❌ Olvidar el formato de salida

✅ Forzar JSON o esquemas estrictos

❌ El mito del Experto Genérico

✅ Usar roles solo para tono y estilo, no para factibilidad

❌ Falta de ejemplos negativos

✅ Incluir edge cases explícitos

❌ EmotionPrompt universal

✅ Reservar para tareas creativas o complejas

El Blueprint 2025: Arquitectura universal

El estándar de producción agrupa el contexto en etiquetas XML para evitar alucinaciones y estructurar la atención del modelo.



```
<role> Define el dominio y estilo </role>  
<context> Datos relevantes y constraints </context>  
<task> El objetivo principal, desglosado </task>  
<rules> Restricciones duras operativas </rules>  
<examples> Demostraciones Few-shot diversas </examples>  
<output_format> Esquema JSON o Markdown esperado </output_format>
```


Medición de éxito y testing continuo

El cambio de métricas: Dejar atrás BLEU/ROUGE. La norma actual es LLM-as-a-judge (G-EVAL), Pass@k, y Exact Match.

Operaciones (LLMOps): Prohibido hacer one-shot prompting en producción. El estándar exige A/B testing y Regression testing.

